Пятое задание по программированию

Деревья решений в scikit-learn

Теоретические положения, критерии качества и примеры реализации

Содержательные акценты
• рекурсивное разбиение пространства признаков и принцип выбора узлов
• критерии Джини, энтропия, MSE и MAE
• учебные примеры классификации и регрессии на Python

Далее приведен основной материал по теме с сохранением ключевых примеров, формул и программных фрагментов.

Формат представления: PDF-документ с теоретической частью и практическими иллюстрациями на Python.

Деревья решений (Decision Trees) в scikit-learn

1. Основные концепции. Математическая формулировка

Дерево решений рекурсивно разбивает пространство признаков:

Узел m содержит данные Q_m с n_m выборками

Разбиение θ = (j, t_m) - признак j и порог t_m

Качество разбиения:

G(Q_m, θ) = (n_left/n_m)·H(Q_left) + (n_right/n_m)·H(Q_right)

2. Критерии качества. Для классификации

p_mk = (1/n_m) * Σ I(y = k) # *Доля класса k в узле m*

H(Q_m) = Σ p_mk(1 - p_mk) # *Джини*

H(Q_m) = -Σ p_mk log(p_mk) # *Энтропия (Log Loss)*

Для регрессии

MSE (среднее квадратичное отклонение)

y_m = (1/n_m) Σ y

H(Q_m) = (1/n_m) Σ (y - y_m)²

H(Q_m) = (1/n_m) Σ |y - median(y)_m|

MAE (среднее абсолютное отклонение)

3. Практическая реализация. Задача 1: Классификация на Iris

```
import numpy as np
from sklearn.datasets import load_iris
from sklearn.tree import DecisionTreeClassifier, plot_tree, export_text
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report, confusion_matrix
import matplotlib.pyplot as plt
# Загрузка данных
iris = load_iris()
X, y = iris.data, iris.target
# Разделение на обучающую и тестовую выборки
X_train, X_test, y_train, y_test = train_test_split(
```

```
    X, y, test_size=0.3, random_state=42
)
# Создание и обучение модели
clf = DecisionTreeClassifier(
    max_depth=3,          # ограничиваем глубину
    min_samples_split=5,   # мин. образцов для разбиения
    min_samples_leaf=2,    # мин. образцов в листе
    criterion='gini',      # критерий Джини
    random_state=42
)
clf.fit(X_train, y_train)
# Предсказание
y_pred = clf.predict(X_test)
y_pred_proba = clf.predict_proba(X_test)
# Оценка
print("Точность:", clf.score(X_test, y_test))
print("\nОтчет по классификации:")
print(classification_report(y_test, y_pred, target_names=iris.target_names))
# Визуализация дерева
plt.figure(figsize=(20,10))
plot_tree(clf, feature_names=iris.feature_names,
          class_names=iris.target_names, filled=True)
plt.show()
# Текстовое представление
print(export_text(clf, feature_names=iris.feature_names))
```

```
Точность: 1.0
Отчет по классификации:
              precision    recall  f1-score   support
      setosa       1.00      1.00      1.00        19
```

versicolor	1.00	1.00	1.00	13
virginica	1.00	1.00	1.00	13
accuracy			1.00	45
macro avg	1.00	1.00	1.00	45
weighted avg	1.00	1.00	1.00	45

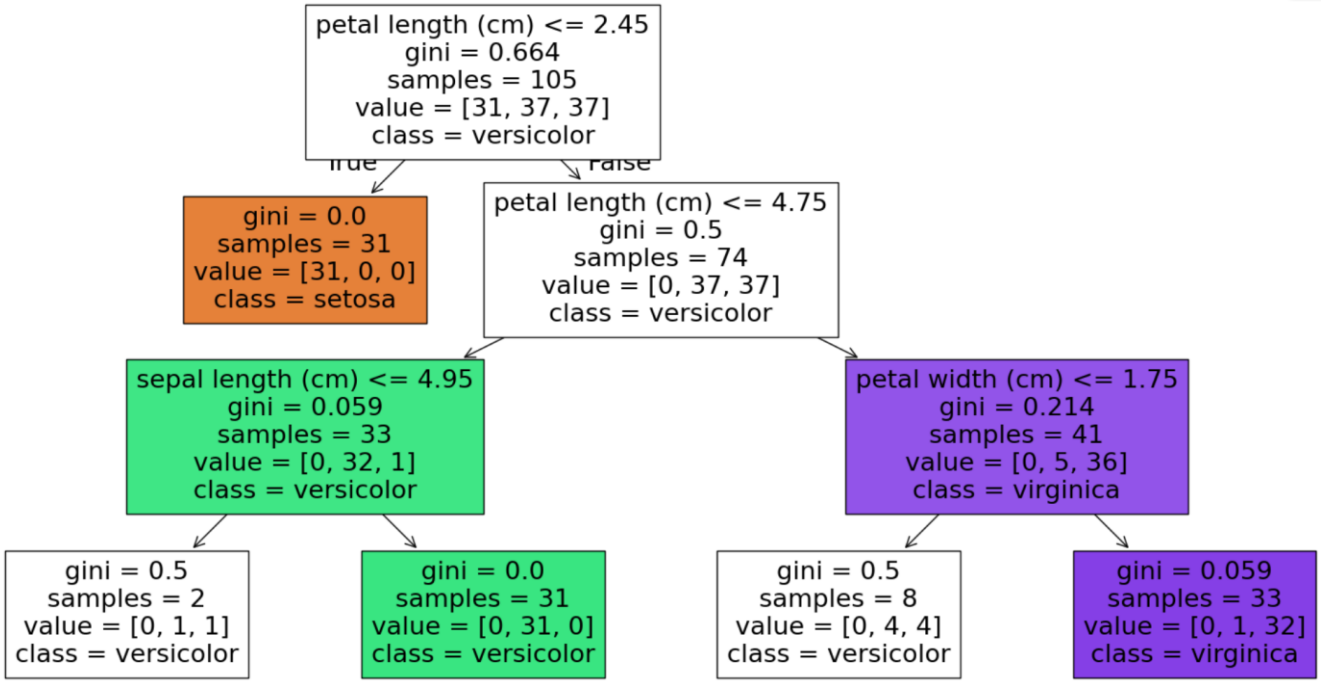


```
|--- petal length (cm) <= 2.45
|   |--- class: 0
|--- petal length (cm) >  2.45
|   |--- petal length (cm) <= 4.75
|   |   |--- sepal length (cm) <= 4.95
|   |   |   |--- class: 1
|   |   |--- sepal length (cm) >  4.95
|   |   |   |--- class: 1
|   |--- petal length (cm) >  4.75
|   |   |--- petal width (cm) <= 1.75
|   |   |   |--- class: 1
|   |   |--- petal width (cm) >  1.75
|   |   |   |--- class: 2
```

Задача 2: Регрессия (синусоида)

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.tree import DecisionTreeRegressor
from sklearn.metrics import mean_squared_error, r2_score
# Генерация данных
np.random.seed(42)
X = np.sort(5 * np.random.rand(80, 1), axis=0)
y = np.sin(X).ravel() + np.random.normal(0, 0.1, X.shape[0])
# Разделение
X_train, X_test = X[:60], X[60:]
y_train, y_test = y[:60], y[60:]
# Сравнение деревьев разной глубины
depths = [2, 5, 10]
plt.figure(figsize=(15, 5))
for i, depth in enumerate(depths, 1):
    # Обучение
    reg = DecisionTreeRegressor(
        max_depth=depth,
        criterion='squared_error',
        min_samples_split=5,
        random_state=42
    )
    reg.fit(X_train, y_train)
    # Предсказание
    y_pred = reg.predict(X_test)
    # Метрики
    mse = mean_squared_error(y_test, y_pred)
    r2 = r2_score(y_test, y_pred)
```

```
    # Визуализация
    plt.subplot(1, 3, i)
    X_plot = np.linspace(0, 5, 100).reshape(-1, 1)
    y_plot = reg.predict(X_plot)
    plt.scatter(X_train, y_train, c='blue', label='Train', alpha=0.6)
    plt.scatter(X_test, y_pred, c='red', label='Predictions', alpha=0.6)
    plt.plot(X_plot, y_plot, 'g-', label='Model')
    plt.plot(X_plot, np.sin(X_plot), 'k--', label='True sin', alpha=0.5)
    plt.title(f'Глубина = {depth}\nMSE = {mse:.3f}, R² = {r2:.3f}')
    plt.xlabel('X')
    plt.ylabel('y')
    plt.legend()
plt.tight_layout()
plt.show()
```

...

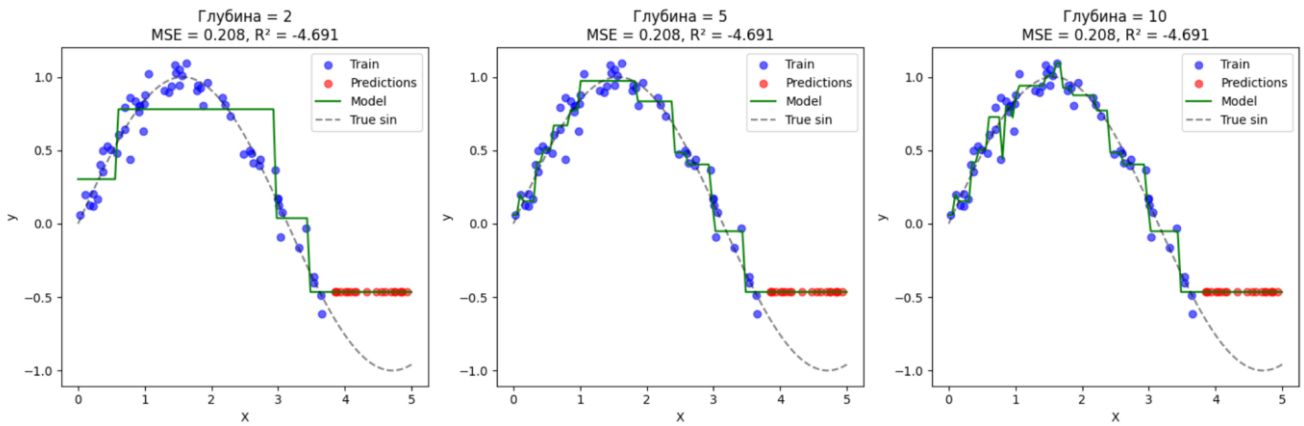

Задача 3: Обрезка дерева (Cost-complexity pruning)

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.datasets import make_classification
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
# Генерация данных
X, y = make_classification(
    n_samples=500, n_features=10, n_informative=5,
```

```
    n_redundant=0, random_state=42
)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42
)
# Обучение дерева без обрезки
clf = DecisionTreeClassifier(random_state=42)
clf.fit(X_train, y_train)
print(f"Без обрезки - узлов: {clf.tree_.node_count}, "
      f"глубина: {clf.tree_.max_depth}")
# Получение пути обрезки
path = clf.cost_complexity_pruning_path(X_train, y_train)
ccp_alphas = path.ccp_alphas
# Обучение деревьев с разными alpha
clfs = []
for ccp_alpha in ccp_alphas:
    clf = DecisionTreeClassifier(random_state=42, ccp_alpha=ccp_alpha)
    clf.fit(X_train, y_train)
    clfs.append(clf)
# Оценка качества
train_scores = [clf.score(X_train, y_train) for clf in clfs]
test_scores = [clf.score(X_test, y_test) for clf in clfs]
# Визуализация
fig, ax = plt.subplots(2, 1, figsize=(10, 8))
ax[0].plot(ccp_alphas, train_scores, 'b-', label='Train')
ax[0].plot(ccp_alphas, test_scores, 'r-', label='Test')
ax[0].set_xlabel('alpha')
ax[0].set_ylabel('Accuracy')
ax[0].legend()
```

```
ax[0].set_title('Accuracy vs alpha')
node_counts = [clf.tree_.node_count for clf in clfs]
depth_counts = [clf.tree_.max_depth for clf in clfs]
ax[1].plot(ccp_alphas, node_counts, 'g-', label='Nodes')
ax[1].plot(ccp_alphas, depth_counts, 'y-', label='Depth')
ax[1].set_xlabel('alpha')
ax[1].set_ylabel('Complexity')
ax[1].legend()
ax[1].set_title('Tree complexity vs alpha')
plt.tight_layout()
plt.show()
# Выбор оптимального alpha
best_idx = np.argmax(test_scores)
best_alpha = ccp_alphas[best_idx]
print(f"\nОптимальный alpha: {best_alpha:.4f}")
print(f"Точность на тесте: {test_scores[best_idx]:.3f}")
```

```
Без обрезки - узлов: 57, глубина: 8
```

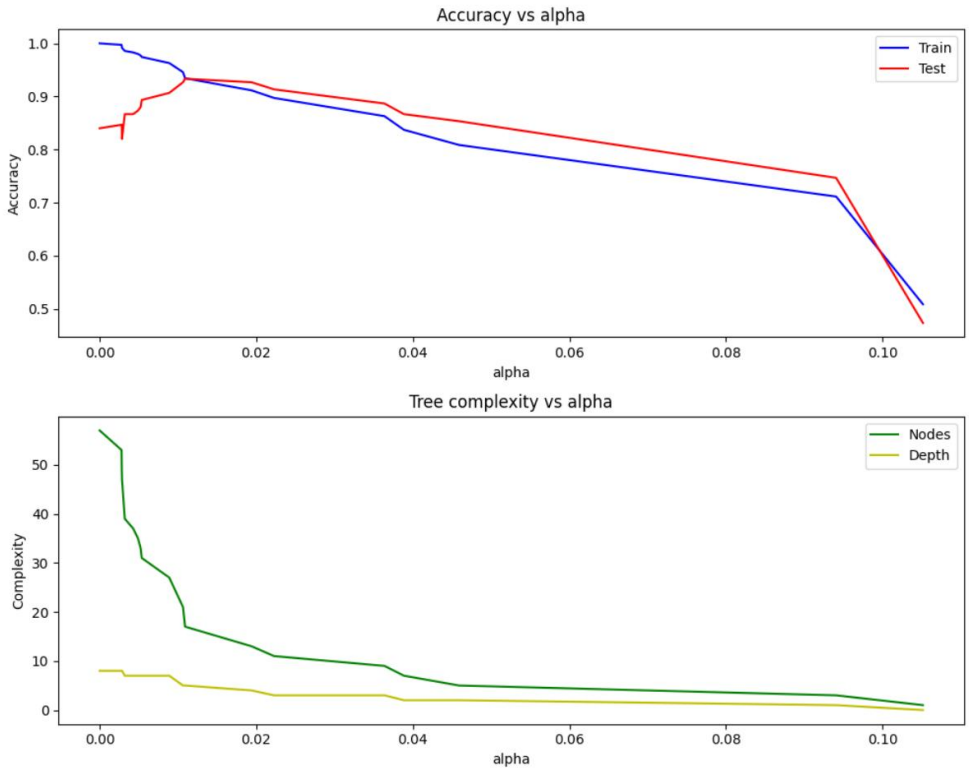


```
Оптимальный alpha: 0.0109
Точность на тесте: 0.933
```

4. Ключевые параметры

Параметр	*Описание*	*Рекомендация*
max_depth	Макс. глубина дерева	Начать с 3-5
min_samples_split	Мин. образцов для разбиения	02.окт
min_samples_leaf	Мин. образцов в листе	01.май
criterion	Функция качества	'gini' или 'entropy'
ccp_alpha	Параметр обрезки	Подбирать через path

5. Интерпретация результатов. Важность признаков

```
# Важность признаков
importances = clf.feature_importances_
for name, importance in zip(iris.feature_names, importances):
    print(f"{name}: {importance:.3f}")
# Визуализация
plt.figure(figsize=(8, 4))
plt.bar(iris.feature_names, importances)
plt.title('Важность признаков')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```

Структура дерева # *Информация о дереве*

```
n_nodes = clf.tree_.node_count
children_left = clf.tree_.children_left
children_right = clf.tree_.children_right
feature = clf.tree_.feature
threshold = clf.tree_.threshold
print(f"Всего узлов: {n_nodes}")
for i in range(n_nodes):
    if children_left[i] != children_right[i]:  # не лист
        print(f"Узел {i}: признак {feature[i]} <= {threshold[i]:.2f}")
```

6. Выводы

1. **Деревья решений** - интерпретируемые модели, склонные к переобучению
2. **Ключевые параметры** для контроля сложности: max_depth, min_samples_leaf
3. **Обрезка** (ccp_alpha) помогает найти баланс между смещением и дисперсией
4. **Важность признаков** дает понимание влияния переменных
5. **Визуализация** помогает понять логику принятия решений