Методы регрессии в scikit-learn

1. Общая характеристика регрессионных моделей

Регрессионные методы в машинном обучении предназначены для восстановления зависимости между входными признаками и числовой целевой переменной. В отличие от задач классификации, где результатом является принадлежность к классу, в регрессии модель должна выдать конкретное числовое значение.

С практической точки зрения регрессия используется в задачах прогнозирования: стоимости, времени, температуры, нагрузки и других количественных показателей.
Модель стремится выявить закономерность в данных и представить её в виде функции, которая на основе входных признаков позволяет вычислить значение целевой переменной.

Одним из ключевых аспектов является то, что модель не просто запоминает значения, а формирует зависимость, способную обобщаться на новые данные.

2. Математическая постановка задачи

Пусть задана обучающая выборка:

$$(X, y) = \{(x_i, y_i)\}_{i=1}^{n}$$

где:

- xi — вектор признаков
- yi — соответствующее числовое значение

Задача регрессии заключается в построении функции:

$$\hat{y} = f(x)$$

которая минимизирует ошибку между реальными значениями и предсказаниями.

Наиболее распространенной функцией потерь является среднеквадратичная ошибка:

$$MSE = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$$

Также используются:

Средняя абсолютная ошибка:

$$MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$$

Коэффициент детерминации:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

Таким образом, задача сводится к поиску такой функции, которая обеспечивает минимальное расхождение между прогнозами и реальными значениями.

3. Основные методы регрессии

3.1. Линейная регрессия

Линейная регрессия предполагает, что зависимость между переменными может быть выражена линейной функцией:

$$y = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

Модель подбирает коэффициенты wiw_iwi, минимизируя ошибку.

3.2. Ridge-регрессия

Данный метод вводит штраф за большие значения коэффициентов:

$$\sum (y_i - \hat{y}_i)^2 + \alpha \sum w_i^2$$

Это позволяет уменьшить переобучение и сделать модель более устойчивой.

3.3. Lasso-регрессия

В отличие от Ridge, используется L1-регуляризация:

$$\sum (y_i - \hat{y}_i)^2 + \alpha \sum |w_i|$$

Особенность метода заключается в том, что он может занулять некоторые коэффициенты, тем самым выполняя отбор признаков.

4. Практическая реализация

Задача 1. Линейная регрессия

```
import numpy as np
import matplotlib.pyplot as plt

from sklearn.datasets import make_regression
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

# Генерация данных
X, y = make_regression(
    n_samples=200,
    n_features=1,
    noise=15,
    random_state=42
)

# Разделение
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.25,
    random_state=42
)

# Модель
model = LinearRegression()
model.fit(X_train, y_train)

# Предсказание
y_pred = model.predict(X_test)

# Оценка
print("MSE:", mean_squared_error(y_test, y_pred))
print("R2:", r2_score(y_test, y_pred))

# Визуализация
plt.scatter(X_test, y_test, label="Данные")
plt.plot(X_test, y_pred, color='red', label="Модель")
plt.legend()
```

```
plt.title("Линейная регрессия")
plt.show()
```

Пояснение
Модель строит прямую линию, которая наилучшим образом описывает зависимость между признаками и целевой переменной.
Если данные действительно имеют линейную структуру, модель показывает высокую точность.

```
MSE: 271,2327998592215
R2: 0,9663146499644847
```

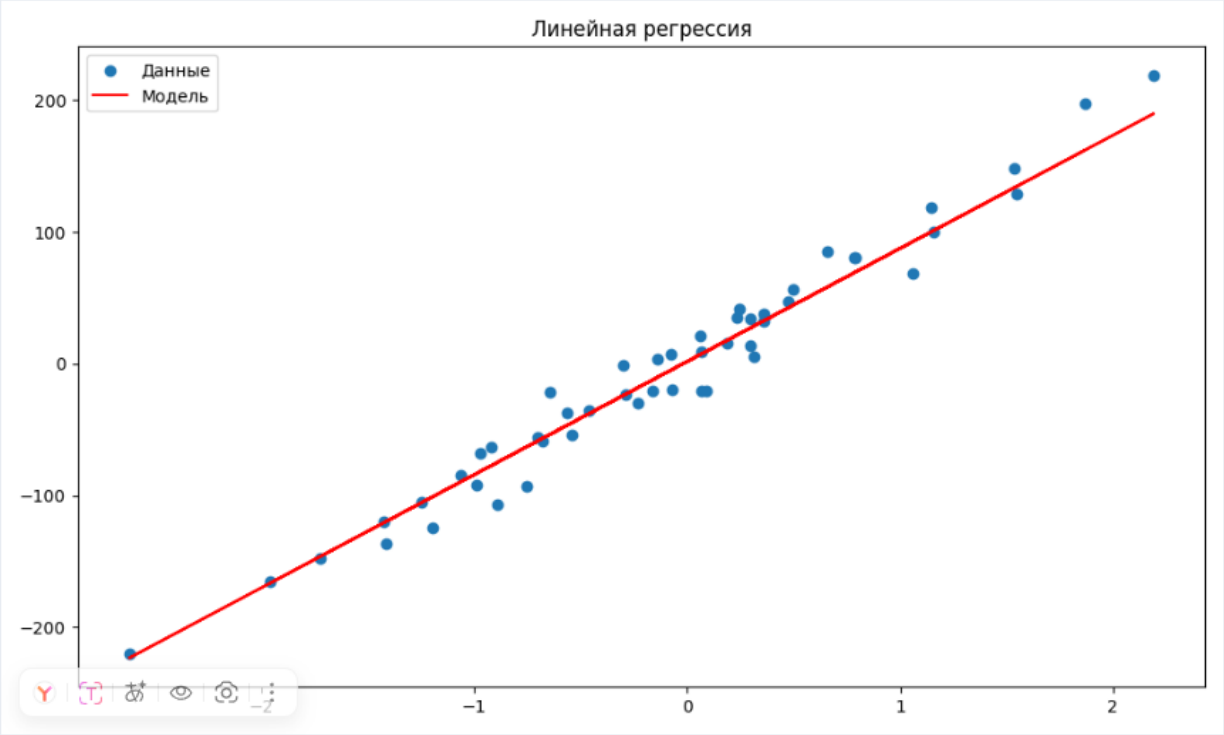

Задача 2. Ridge и Lasso

```
from sklearn.linear_model import Ridge, Lasso

# Ridge
ridge = Ridge(alpha=1.0)
ridge.fit(X_train, y_train)
ridge_pred = ridge.predict(X_test)

# Lasso
lasso = Lasso(alpha=0.1)
lasso.fit(X_train, y_train)
lasso_pred = lasso.predict(X_test)

print("Ridge R2:", r2_score(y_test, ridge_pred))
print("Lasso R2:", r2_score(y_test, lasso_pred))
```

```
Ridge R2: 0,9655063754669757
Лассо R2: 0,9661804132494214
```

Пояснение
Оба метода добавляют регуляризацию, но делают это по-разному.
Ridge сглаживает коэффициенты, а Lasso может исключать признаки, что полезно при большом количестве входных переменных.

Задача 3. Полиномиальная регрессия

```
from sklearn.preprocessing import PolynomialFeatures
from sklearn.pipeline import make_pipeline

# Полиномиальная модель
poly_model = make_pipeline(
    PolynomialFeatures(degree=3),
    LinearRegression()
)

poly_model.fit(X_train, y_train)
y_poly_pred = poly_model.predict(X_test)

print("R2 (poly):", r2_score(y_test, y_poly_pred))
```

```
R2 (полиномиальная): 0,9658816907500244
```

Пояснение
Полиномиальная регрессия позволяет моделировать нелинейные зависимости, расширяя пространство признаков.
Это дает возможность описывать более сложные зависимости, чем простая линейная модель.

5. Основные параметры моделей

alpha

Коэффициент регуляризации.
Чем больше значение, тем сильнее штраф за большие коэффициенты.

fit_intercept

Определяет, учитывать ли свободный член в модели.

normalize (устаревший параметр)

Ранее использовался для нормализации данных.

6. Анализ результатов

Влияние регуляризации

При увеличении параметра alpha:

- уменьшается разброс коэффициентов
- снижается переобучение
- модель становится более устойчивой

Однако слишком большое значение может ухудшить точность.

Интерпретация коэффициентов

Коэффициенты модели показывают, насколько сильно каждый признак влияет на результат.
Положительное значение увеличивает прогноз, отрицательное — уменьшает.

7. Задачи для проверки понимания

Задание 1
В чем отличие регрессии от классификации?

Ответ
Регрессия предсказывает числовое значение, тогда как классификация определяет принадлежность к категории.

Задание 2
Что показывает коэффициент R^2?

Ответ
Он отражает долю объясненной дисперсии. Чем ближе значение к 1, тем лучше модель объясняет данные.

Задание 3
Зачем используется регуляризация?

Ответ
Для предотвращения переобучения и уменьшения чувствительности модели к шуму.

Задание 4
В чем разница между Ridge и Lasso?

Ответ
Ridge уменьшает коэффициенты, а Lasso может занулять их, выполняя отбор признаков.

Задание 5
Когда стоит использовать полиномиальную регрессию?

Ответ
Когда зависимость между признаками и целевой переменной является нелинейной.

8. Выводы

Регрессионные модели являются важным инструментом анализа данных, позволяющим выявлять количественные зависимости.
Линейная регрессия обеспечивает простую и интерпретируемую модель, тогда как методы с регуляризацией позволяют контролировать сложность и устойчивость.
Использование полиномиальных признаков расширяет возможности модели и позволяет учитывать нелинейные зависимости.
Выбор конкретного метода определяется структурой данных и требованиями к точности и интерпретируемости модели.