Наивный байесовский классификатор (Naive Bayes) в scikit-learn

1. Общая идея метода

Наивный байесовский классификатор представляет собой вероятностный метод машинного обучения, основанный на применении теоремы Байеса. Основная задача модели заключается в оценке вероятности принадлежности объекта к определенному классу на основе его признаков.

Ключевая особенность метода заключается в предположении независимости признаков. Это означает, что модель рассматривает каждый признак как независимый от остальных, несмотря на то, что в реальных данных это условие часто не выполняется. Тем не менее, даже при нарушении этого предположения классификатор показывает достаточно устойчивые результаты.

Метод широко применяется в задачах обработки текстов, фильтрации спама, анализа отзывов и других задачах, где важна скорость обучения и простота реализации.

2. Математическая основа

Пусть необходимо определить класс yyy для объекта с признаками x=(x1,x2,...,xn).

Согласно теореме Байеса:

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)}$$

Так как P(x) одинаково для всех классов, задача сводится к максимизации:

$$P(y|x) \propto P(y) \cdot P(x|y)$$

При наивном предположении независимости признаков:

$$P(x|y) = \prod_{i=1}^{n} P(x_i|y)$$

Итоговая формула классификации принимает вид:

$$y = \arg\max_y P(y) \prod_{i=1}^{n} P(x_i|y)$$

Таким образом, модель выбирает тот класс, для которого вероятность оказывается максимальной.

3. Виды наивного байесовского классификатора

3.1. Gaussian Naive Bayes

Используется для непрерывных признаков. Предполагается, что значения признаков распределены нормально.

$$P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)$$

3.2. Multinomial Naive Bayes

Применяется для дискретных данных, например, частоты слов в тексте. Часто используется в задачах обработки естественного языка.

3.3. Bernoulli Naive Bayes

Работает с бинарными признаками (0 или 1). Подходит для задач, где важно наличие или отсутствие признака.

4. Практическая реализация

Задача 1. Классификация на наборе Iris

```
import numpy as np
import matplotlib.pyplot as plt

from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import accuracy_score, classification_report

# Загрузка данных
iris = load_iris()
X, y = iris.data, iris.target

# Разделение
X_train, X_test, y_train, y_test = train_test_split(
```

```
    X, y,
    test_size=0.25,
    random_state=42
)

# Модель
model = GaussianNB()
model.fit(X_train, y_train)

# Предсказание
y_pred = model.predict(X_test)

# Оценка
print("Accuracy:", accuracy_score(y_test, y_pred))
print(classification_report(y_test, y_pred))
```

```
Точность: 1,0
 точность, полнота, F-мера, поддержка

           0       1.00      1.00      1.00        15
           1       1.00      1.00      1.00        11
           2       1.00      1.00      1.00        12

 точность 1,00 38
 среднее значение 1,00 1,00 1,00 38
средневзвешенное значение 1,00 1,00 1,00 38
```

Пояснение
В данном примере модель определяет вид растения по его характеристикам. Алгоритм оценивает распределения признаков внутри каждого класса и на их основе вычисляет вероятности.

Задача 2. Классификация текстовых данных

```
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.naive_bayes import MultinomialNB

# Простейший текстовый датасет
texts = [
"space rocket launch",
"satellite orbit earth",
"galaxy and stars",
"car engine repair",
"vehicle speed highway",
```

```
"auto mechanics service"
]

# Классы: 0 - космос, 1 - автомобили
labels = [0, 0, 0, 1, 1, 1]

# Векторизация
vectorizer = CountVectorizer()
X = vectorizer.fit_transform(texts)

# Обучение
model = MultinomialNB()
model.fit(X, labels)

# Предсказание
test_data = ["space mission", "car engine problem"]
X_test = vectorizer.transform(test_data)

predictions = model.predict(X_test)

print("Predictions:", predictions)
```

```
Прогнозы: [0 1]
```

Пояснение
Каждый текст преобразуется в вектор частот слов.
Модель оценивает вероятность появления слов в каждом классе и на основе этого принимает решение.

Задача 3. Влияние сглаживания (Laplace smoothing)

```
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import accuracy_score

# Локальные данные (как в задаче 2)
texts = [
"space rocket launch",
"satellite orbit earth",
"galaxy stars universe",
"car engine repair",
"vehicle speed highway",
"auto mechanics service"
]
```

```
labels = [0, 0, 0, 1, 1, 1]

# Векторизация
vectorizer = CountVectorizer()
X = vectorizer.fit_transform(texts)
y = labels

# Проверка разных alpha
alphas = [0.0, 0.5, 1.0, 2.0]

for alpha in alphas:
model = MultinomialNB(alpha=alpha)
model.fit(X, y)

preds = model.predict(X)
acc = accuracy_score(y, preds)

print(f"alpha={alpha}, accuracy={acc:.3f}")
```

```
alpha=0.0, точность=1.000
альфа=0,5, точность=1,000
alpha=1.0, точность=1.000
alpha=2.0, точность=1.000
```

Пояснение
Параметр alpha используется для сглаживания вероятностей.
Он предотвращает ситуацию, когда вероятность становится равной нулю, если признак не встречался в обучающей выборке.

5. Основные параметры модели

alpha

Коэффициент сглаживания.
Позволяет избежать нулевых вероятностей.

fit_prior

Определяет, учитывать ли априорные вероятности классов.

class_prior

Позволяет задать вероятности классов вручную.

6. Интерпретация результатов

Вероятности классов

Модель может возвращать не только класс, но и вероятность:

```
probs = model.predict_proba(X_test)
print(probs[:5])
```

Это позволяет оценить уверенность модели.

Влияние признаков

В текстовых задачах можно определить, какие слова сильнее влияют на классификацию, анализируя вероятности слов внутри классов.

7. Задачи для проверки понимания

Задание 1
В чем заключается "наивность" метода?

Ответ
В предположении, что все признаки независимы друг от друга.

Задание 2
Почему можно отбросить P(x)P(x)P(x) в формуле Байеса?

Ответ
Потому что оно одинаково для всех классов и не влияет на выбор максимума.

Задание 3
Зачем нужен параметр alpha?

Ответ
Для сглаживания вероятностей и предотвращения нулевых значений.

Задание 4
В каких задачах особенно эффективен Naive Bayes?

Ответ
В задачах обработки текстов и классификации документов.

Задание 5
Чем отличается GaussianNB от MultinomialNB?

Ответ
GaussianNB работает с непрерывными признаками, а MultinomialNB — с дискретными.

8. Выводы

Наивный байесовский классификатор представляет собой простой и эффективный метод, основанный на вероятностном подходе.
Несмотря на упрощающее предположение независимости признаков, он демонстрирует хорошие результаты в ряде практических задач.
Метод отличается высокой скоростью обучения и низкими вычислительными затратами, что делает его удобным для работы с большими объемами данных.
Особенно эффективен он в задачах текстовой классификации, где признаки естественным образом представлены в виде частот.